

Projet Intégré
Analyse et Prédiction du Churn Client

Description des Données

Encadrant

2026

Table des matières

1	Description des Données	2
1.1	1. Vue d'ensemble	2
1.2	2. Fichier principal — Description des colonnes	2
1.2.1	2.1 Identifiants	2
1.2.2	2.2 Informations client	2
1.2.3	2.3 Informations compte	3
1.2.4	2.4 Informations produit	3
1.3	3. Tables de dimensions	3
1.4	4. Définition de la variable cible (churn)	4
1.5	5. Variables potentiellement intéressantes pour le ML	4
1.6	6. Qualité des données — points d'attention	4
1.7	7. Volumétrie indicative	5
1.8	8. Précautions	5

1. Description des Données

Les données mises à votre disposition proviennent du système d'information d'une institution bancaire. Elles ont été **anonymisées** : aucun identifiant personnel direct n'est exploitable, mais elles conservent leur structure et leur cohérence métier réelle.

1.1 1. Vue d'ensemble

Le jeu de données est composé de :

- **1 fichier de données principal** au format CSV (~130 Mo, plusieurs centaines de milliers de lignes) contenant les informations clients, comptes et produits.
- **8 tables de dimensions** au format Excel (.xlsx) qui donnent le libellé descriptif associé aux codes présents dans le fichier principal.

Chaque ligne du fichier principal correspond à un **couple (client, compte produit)** : un même client peut donc apparaître plusieurs fois s'il possède plusieurs comptes.

1.2 2. Fichier principal — Description des colonnes

1.2.1 2.1 Identifiants

Colonne	Type	Description
CUSTOMER_NO	Numérique	Identifiant unique du client
ACCOUNT_NO	Numérique	Identifiant unique du compte
BRANCH	Code	Agence de rattachement

1.2.2 2.2 Informations client

Colonne	Type	Description
NATIONALITY	Code ISO	Nationalité du client
RESIDENCE	Code ISO	Pays de résidence
MARITAL_STATUS	Code	Statut marital (C = célibataire, M = marié(e), D = divorcé(e), V = veuf/veuve)
DATE_OF_BIRTH	Date (YYYYMMDD)	Date de naissance
CUST_OPENING_DATE	Date (YYYYMMDD)	Date d'entrée en relation avec la banque
NATURE_CLIENT	Code	Type de client (personne physique, personne morale, etc.)
PARTYCLASS	Code	Classification commerciale (Retail, Corporate, etc.)
LOB	Code	Ligne métier (Line of Business)
SCORE_KYC	Code	Score de connaissance client (Know Your Customer)
COMPLETED_FILE	Booléen (YES/NO)	Dossier client complet

Colonne	Type	Description
LAST_REVIEW_DATE	Date	Date de dernière revue du dossier
NEXT__REVIEW_DATE	Date	Date de prochaine revue prévue
INDUSTRY	Code	Secteur d'activité du client (FK vers dim_INDUSTRY)
SALARY	Numérique	Salaire ou revenu déclaré

1.2.3 2.3 Informations compte

Colonne	Type	Description
ACCOUNT_STATUS	Texte	Statut du compte (Active, Closed, etc.) — variable cible pour le churn
ACCT_OPENING_DATE	Date	Date d'ouverture du compte
ACCT_CLOSE_DATE	Date	Date de clôture du compte (si applicable)
ACCOUNT_CATEGORY	Code	Catégorie du compte (FK vers dim_CATEGORY.ACCOUNT)
ACCOUNT_TYPE_DESC	Texte	Description du type de compte
CURRENCY	Code ISO	Devise du compte (FK vers dim_CURRENCY)
CLOSURE_REASON	Code	Motif de clôture (FK vers dim_Closure_reason)
ACCT_BALANCE	Numérique	Solde du compte

1.2.4 2.4 Informations produit

Colonne	Type	Description
PRODUCT_GROUP	Code	Groupe de produits
PRODUCT_LINE	Code	Ligne de produits
PRODUCT	Code	Produit spécifique
ACCOUNTNATURE	Texte	Nature du produit
STARTDATE	Date	Date de début du produit
MATURITYDATE	Date	Date d'échéance
AMOUNT	Numérique	Montant du produit (crédit, dépôt, etc.)
FIXEDRATE	Numérique	Taux fixe associé
PRODUCT_STATUS	Texte	Statut du produit

1.3 3. Tables de dimensions

Les fichiers `dim_*.xlsx` fournissent les libellés descriptifs associés aux codes du fichier principal. Elles sont à utiliser pour enrichir les données lors de la phase ETL.

Fichier	Clé	Contenu
dim_CATEGORY.ACCOUNT.xlsx	CATEGORY_id	Description des catégories de compte
dim_CURRENCY.xlsx	Code devise	Description des devises
dim_Closure_reason.xlsx	RECID	Motifs de clôture de compte
dim_DAO.xlsx	Code	Référentiel DAO
dim_INDUSTRY.xlsx	INDUSTRY_CODE	Secteurs d'activité économique
dim_SECTOR.xlsx	Code	Secteurs détaillés
dim_TARGET.xlsx	Code	Segmentation cible client
dim_TRANSACTION.xlsx	Code	Référentiel de types de transactions

1.4 4. Définition de la variable cible (churn)

Le **churn** se définit ici comme la **clôture d'un compte client**. La variable cible peut être construite à partir de la colonne `ACCOUNT_STATUS` :

```
churn = 1 si ACCOUNT_STATUS contient "Closed"
churn = 0 sinon
```

Vous pouvez aussi proposer une définition plus fine (par exemple : churn d'un client = clôture de **tous** ses comptes), à justifier dans le rapport.

1.5 5. Variables potentiellement intéressantes pour le ML

Quelques pistes (non exhaustives) à explorer :

- **Variables démographiques** : âge (à calculer depuis `DATE_OF_BIRTH`), statut marital, nationalité.
- **Variables d'ancienneté** : ancienneté du client (`CUST_OPENING_DATE`), ancienneté du compte (`ACCT_OPENING_DATE`).
- **Variables financières** : solde (`ACCT_BALANCE`), salaire (`SALARY`), montant du produit (`AMOUNT`).
- **Variables comportementales** : nombre de comptes par client, diversité des produits détenus, secteur d'activité, segment commercial.
- **Variables de conformité** : score KYC, dossier complet ou non, ancienneté de la dernière revue.

1.6 6. Qualité des données — points d'attention

Le jeu de données est issu d'un système opérationnel réel. Vous rencontrerez donc :

- Des **valeurs manquantes** dans plusieurs colonnes (`SALARY`, `INDUSTRY`, dates, etc.).
- Des **valeurs NULL textuelles** à distinguer des NaN.
- Des **dates au format YYYYMMDD numérique** à convertir.
- Des **incohérences** possibles (dates de clôture sans statut `Closed`, soldes négatifs, etc.).
- Un **déséquilibre de classes** entre comptes actifs et clos qu'il faudra prendre en compte dans le modèle ML.

Une phase de **profilage et d'analyse exploratoire** est donc indispensable avant toute modélisation.

1.7 7. Volumétrie indicative

- Fichier principal : ~130 Mo, plusieurs centaines de milliers de lignes.
- Tables de dimensions : entre 6 ko et 80 ko chacune.

La volumétrie est suffisamment importante pour justifier une approche structurée (Pandas avec chunks, ou base de données analytique), mais reste manipulable sur une machine standard.

1.8 8. Précautions

- **Ne pas publier les données** sur GitHub ou tout autre dépôt public.
- **Ne pas mentionner** l'origine des données dans aucun livrable.
- Utiliser un `.gitignore` qui exclut au minimum : `*.csv`, `*.xlsx`, `*.pkl`, `data/`.